

A3 HyperMegaLogLog Pro Max++

Реализация

Генерация потока (RandomStreamGen)

Реализован генератор строк:

- длина строки: от 1 до 30 символов;
- алфавит: a-z , A-Z , 0-9 , - ;
- поток формируется с повторениями через параметр reuse_prob .

Моменты времени t задаются как префиксы потока с шагом 5%:

$$t \in \{0.05n, 0.10n, \dots, 1.00n\}.$$

Генерация хеш-функции (HashFuncGen)

Используется схема:

1. Базовый хеш строки: FNV-1a 64-bit.
2. Линейное преобразование:

$$h(x) = (a \cdot x + b) \bmod 2^{32},$$

где a, b выбираются случайно, a делается нечётным.

HyperLogLog

Для каждого элемента:

1. Вычисляется 32-битный хеш.
2. Первые B бит идут в индекс регистра.
3. По оставшимся битам вычисляется ρ (позиция первого 1).
4. Регистр обновляется максимумом.

Оценка:

$$\hat{N} = \alpha_m \cdot m^2 \left(\sum_{j=1}^m 2^{-M_j} \right)^{-1},$$

где $m = 2^B$, M_j — значение j -го регистра.

Также применены стандартные поправки:

- small-range (linear counting),
- large-range для 32-битного пространства.

Параметры эксперимента

- число потоков: NUM_STREAMS = 30 ,
- длина потока: STREAM_SIZE = 200000 ,
- шаг по времени: STEP_PERCENT = 5 ,
- доля повторов: REUSE_PROB = 0.78 ,
- параметр HLL: B = 12 ,
- число регистров: $m = 2^{12} = 4096$.

Теоретические ориентиры:

$$\frac{1.04}{\sqrt{m}} = \frac{1.04}{64} = 0.01625 \text{ (1.625%)},$$

$$\frac{1.3}{\sqrt{m}} = \frac{1.3}{64} = 0.0203125 \text{ (2.031%).}$$

Методика оценки

На каждом шаге t :

1. Считалось точное значение F_0^t через unordered_set .
2. Считалась оценка HLL N_t .

Далее по 30 потокам вычислялись:

- $E(F_0^t)$,
- $E(N_t)$,
- σ_t (стандартное отклонение оценки),
- относительный сдвиг:

$$bias_{rel}(t) = \frac{E(N_t) - E(F_0^t)}{E(F_0^t)},$$

- относительная RMSE:

$$rmse_{rel}(t) = \frac{\sqrt{E[(N_t - F_0^t)^2]}}{E(F_0^t)},$$

- относительная вариативность:


$$cv_t = \frac{\sigma_t}{E(F_0^t)}.$$

Результаты

Построены графики:


1. Сравнение F_0^t и N_t — кривые почти совпадают на всём диапазоне.

Graph #1: True F0_t vs HLL estimate N_t



2. $E(N_t)$ и полоса неопределённости $E(N_t) \pm \sigma_t$ — полоса узкая и стабильная.

Graph #2: Mean estimate and uncertainty band



- число шагов: 20 ,
- средний $|bias_{rel}|$: 0.003753 (0.375%),
- максимальный $|bias_{rel}|$: 0.021526 (2.153%),
- средний $rmse_{rel}$: 0.014800 (1.480%),
- максимальный $rmse_{rel}$: 0.024115 (2.411%),
- средний cv : 0.016929 (1.693%),
- максимальный cv : 0.022297 (2.230%).

Доли шагов, удовлетворяющих границам:

- $cv_t \leq 1.04/\sqrt{m}$: 40% ,
- $cv_t \leq 1.3/\sqrt{m}$: 95% ,
- $rmse_{rel}(t) \leq 1.3/\sqrt{m}$: 95% .

Дополнительно:

- $rmse_{rel}(t) \leq 1.04/\sqrt{m}$ выполняется для 90% шагов.

Худший шаг по RMSE: $t = 50000$,

- $bias_{rel} \approx +2.15\%$,
- $rmse_{rel} \approx 2.41\%$.

Это единичный выброс на остальных шагах качество существенно лучше.

Сравнение с теорией

1. Точность.

В среднем ошибка соответствует ожидаемому уровню для $B = 12$:

средний $rmse_{rel} = 1.48\%$ близок к теоретическим 1.625%.

2. Стабильность.

Средний $cv = 1.693\%$ находится около теоретического порядка.

Большинство шагов укладывается в ослабленную границу $1.3/\sqrt{m}$.

3. Влияние констант.

Точность определяется главным образом B (т.е. числом регистров $m = 2^B$): при увеличении B ожидается снижение дисперсии и RMSE ценой роста памяти.